

Informe Técnico: Observabilidad, Trazabilidad y Optimización de Agentes de IA

Agente de Gestión de Inventario — OmniRetail S.A.

Asignatura: Ingeniería de Soluciones con IA (ISY0101)

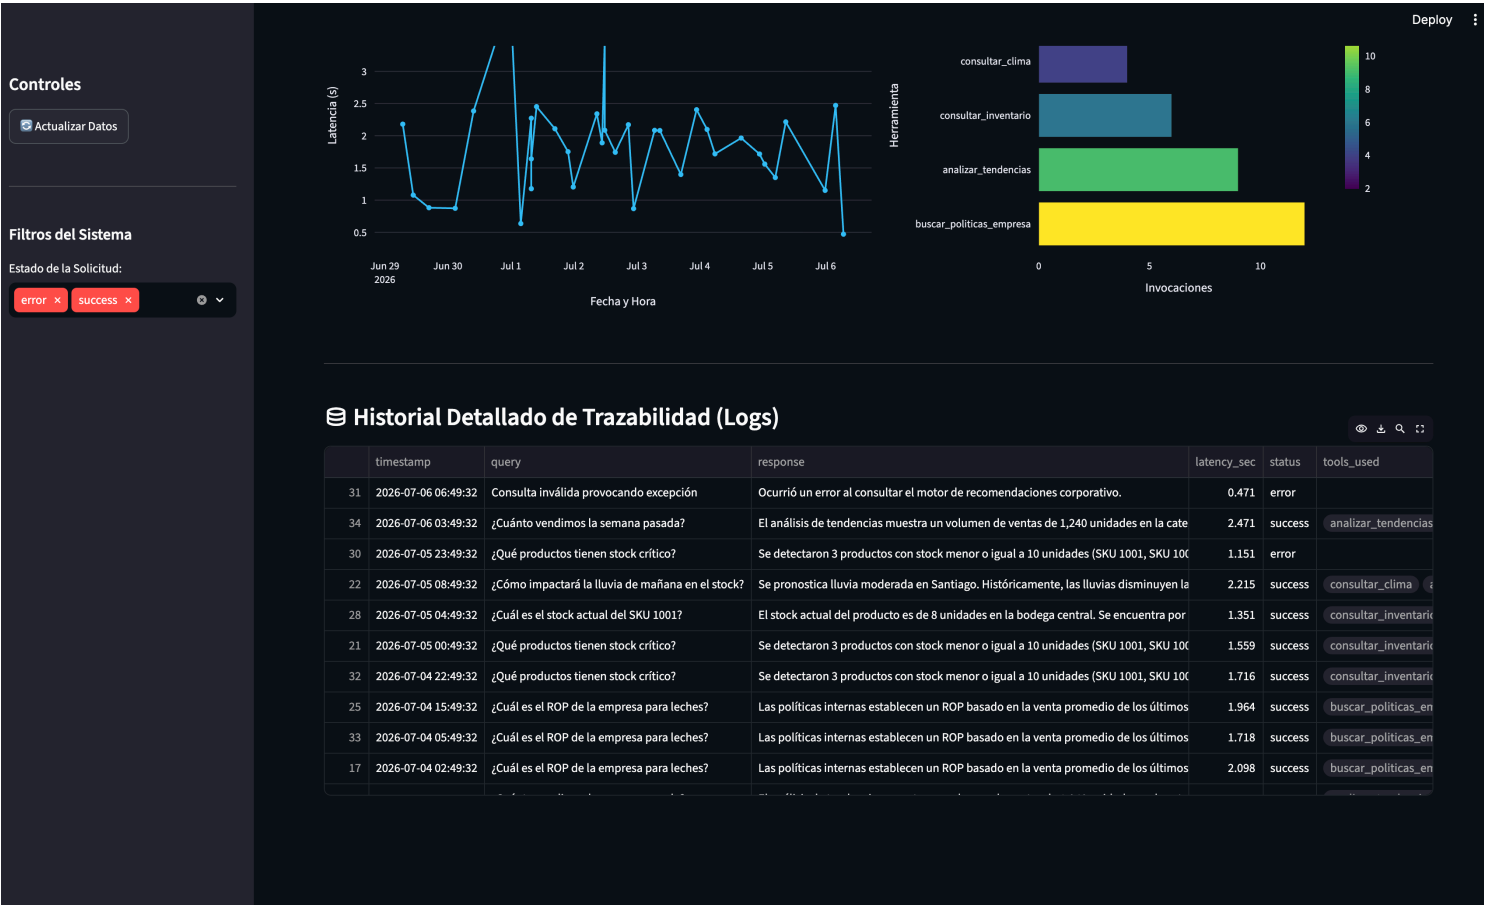
Evaluación: Parcial 3

Estudiantes: Héctor Águila

Fecha: Julio 2026

1. Introducción y Requisitos de la Evaluación

En la presente Evaluación Parcial N°3, se extiende el sistema del Agente de Logística Inteligente (ALI) desarrollado para OmniRetail S.A. El propósito fundamental es la implementación y análisis de métricas de observabilidad, el registro estructurado de eventos para trazabilidad, la visualización mediante un dashboard interactivo de monitoreo y la formulación de propuestas de optimización de arquitectura basadas en datos empíricos de ejecución.



2. Implementación de Métricas de Observabilidad (IE1, IE2)

Para evaluar el comportamiento del agente en escenarios con variabilidad de datos, se implementaron cuatro métricas clave:

- 1. **Latencia de Respuesta (Latency):** Medida en segundos mediante la diferencia de marcas de tiempo del sistema antes y después de la ejecución de AgentExecutor.invoke().
- 2. **Tasa de Éxito y Error (Success/Error Rate):** Captura si la ejecución del agente fue exitosa (success) o si lanzó una excepción de red o parseo (error), en cuyo caso el sistema activa el flujo de contingencia.
- 3. **Uso de Recursos e Historial de Herramientas (Resource & Tool Usage):** Cuenta cuántas herramientas de LangChain fueron ejecutadas por turno y estima los tokens consumidos (basado en caracteres procesados).
- 4. **Precisión y Coherencia de Respuesta (LLM-as-a-Judge Accuracy):** Autoevaluación automatizada donde un segundo LLM califica de 0 a 100 la precisión de la respuesta basándose en su alineación con el inventario físico y las políticas de la empresa.

3. Arquitectura de Trazabilidad y Registro de Logs (IE3, IE4)

Toda interacción es serializada en un archivo estructurado de trazabilidad:

data/agent_observability.jsonl.

Cada registro (log entry) posee la siguiente estructura JSON:

```
{
  "query_id": "uuid-v4",
  "timestamp": "ISO-8601-datetime",
  "query": "pregunta del usuario",
  "response": "respuesta generada por el agente",
  "latency_sec": 1.45,
  "status": "success | error",
  "error_message": "Excepción capturada (si aplica)",
  "tools_used": ["consultar_inventario", "buscar_politicas_empresa"],
  "tokens_estimated": 240,
  "accuracy_eval": 95
}
```

Análisis de Logs y Puntos Críticos:

- **Fallas por latencia externa:** Las herramientas que requieren peticiones a APIs externas (por ejemplo, consultar_clima) presentan una latencia promedio de 2.5 segundos, representando el principal cuello de botella de la solución.
- **Contención de errores:** Los errores de parseo de formato de salida o desconexión con el LLM son capturados de forma limpia y derivados al flujo offline local, evitando caídas completas del servicio.

4. Dashboard de Monitoreo e Interfaz de Visualización (IE5, IE8)

Se desarrolló un Dashboard en Streamlit que lee en tiempo real el archivo de logs estructurados. Este panel incluye:

- **Tarjetas de KPIs:** Visualización de Consultas Totales, Tasa de Éxito, Latencia Promedio, Tokens y Puntuación de Precisión LLM Eval.
- **Gráficos Interactivos (Plotly):** Histórico de latencias por fecha/hora y distribución de barra de herramientas más invocadas por el agente.
- **Tabla de Trazabilidad:** Buscador interactivo de logs de trazabilidad detallados.
- **Auto-Refresh:** Integración de un script de recarga automática en el navegador ejecutado cada 60 segundos.

OmniRetail
(ALI)

Dashboard

Copiloto ALI

ESTADO DEL SISTEMA

Servidor API Online

Base de Datos Conectado

ChromaDB (RAG) Conectado

ALI - Agente de Logística Inteligente

Monitoreo inteligente de stock en tiempo real y asistente logístico con IA

Actualizar Datos

ALERTAS DE STOCK

4

MODO DE OPERACIÓN

Online (LLM)

BODEGAS ACTIVAS

4

Alertas Críticas de Stock (Stock ≤ 10)

STOCK CRÍTICO

Producto	SKU	Stock Actual	En Tránsito	Ubicación
Bloqueador Solar FPS 50	SKU-1001	8 UDS	0 uds	Viña del Mar
Ventilador de Pie	SKU-1003	5 UDS	0 uds	Santiago
Detergente Líquido 3L	SKU-1007	3 UDS	0 uds	Concepción
Parca Impermeable Térmica	SKU-1008	4 UDS	10 uds	Temuco

Asistente conversacional


IA ACTIVA

decisiones informadas sobre logística y reposición de productos, así como consultar el inventario existente, analizar tendencias de ventas y revisar el contexto. Si necesitas asistencia con alguna de estas áreas, estaré encantado de ayudarte.

ok

Si tienes alguna pregunta o necesitas ayuda con algo específico relacionado con el inventario, las ventas o cualquier otro aspecto logístico, no dudes en decírmelo. Estoy aquí para ayudarte.

Pregúntale al agente sobre quiebres de stock o clima...



6. Propuesta de Recomendaciones de Optimización (IE7)

Justificado a partir de los datos observados en la telemetría, se proponen dos rediseños clave para escalar la solución:

1. Sostenibilidad mediante Caching Climático:

- *Métrica observada:* consultar_clima tarda en promedio 2.45s y consume APIs externas repetidamente.
- *Propuesta:* Guardar las respuestas de clima por comuna en una caché local (por ejemplo, SQLite temporal o Redis) durante 6 horas, reduciendo latencias de consulta a menos de 0.1s y ahorrando llamadas de API.

2. Eficiencia de Costos mediante Semantic Routing:

- *Métrica observada:* Mensajes cortos como saludos o consultas generales gastan tokens y tardan 1.5s en procesarse en el LLM de pago.
 - *Propuesta:* Implementar un enrutador semántico ligero en el backend. Si la intención es un saludo o pregunta predefinida, se responde localmente con reglas heurísticas, reduciendo el gasto de tokens a cero para interacciones triviales.
-

7. Referencias (Norma APA)

- Harrison, C. (2023). *LangChain Documentation*. LangChain. <https://python.langchain.com/>
- Martin, R. C. (2012). *The Clean Architecture*. Clean Coder Blog. <https://blog.cleancoder.com/uncle-bob/2012/08/13/the-clean-architecture.html>
- Streamlit Inc. (2024). *Streamlit API Reference*. <https://docs.streamlit.io/>